

赞同 196

分享

详细推导PCA算法



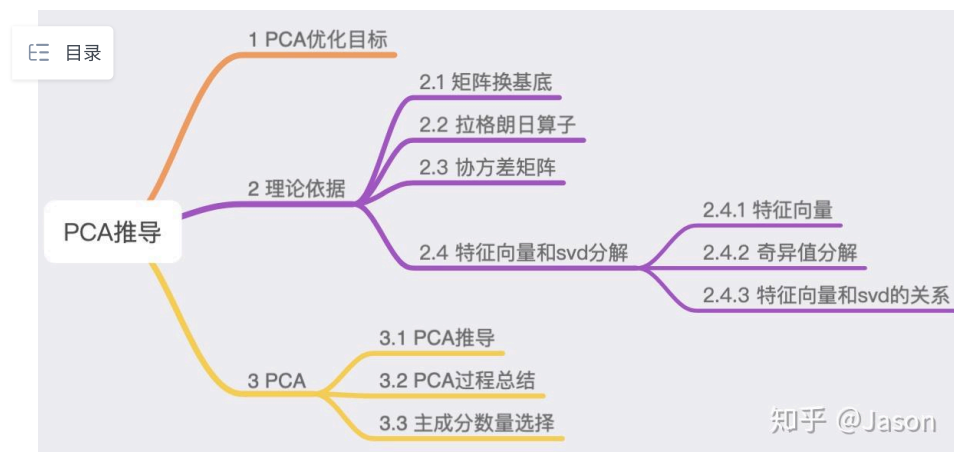
怪兽
一个有点理想的算法攻城狮

关注

来自专栏 · AI怪兽专栏 >

196 人赞同了该文章 >

本文主要思路如下：



1 PCA优化目标

PCA（主成分分析⁺）是一种数据降维⁺的方法，即用较少特征地数据表达较多特征地数据（数据压缩，PCA属于有损压缩）。PCA推导有两种主要思路：

1. 最大化数据投影后的的方差⁺（让数据更分散）
2. 最小化投影造成的损失

本文采用第一种思路完成推导过程，下图中旋转的是新坐标轴，每个数据点在改坐标轴上垂直投影，最佳的坐标轴为数据投影后的数据之间距离最大。




图1 数据投影到新坐标轴


要完成PCA推导过程，需要如下第 2 章部分的理论依据

2 理论依据

2.1 矩阵换基底

坐标变换地目标是，找到一组新的正交单位向量，替换原来的正交单位向量。下面通过具体例子说明。

假设存在向量 $\vec{a} = \begin{bmatrix} 3 \\ 2 \end{bmatrix}$ ，要变换导以 $\vec{u} = \begin{bmatrix} \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{bmatrix}$, $\vec{v} = \begin{bmatrix} -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{bmatrix}$ 为新基底地坐标上，求在
心坐标系中的坐标



知乎 @Jason

∴ 向量 \vec{a} 在向量 \vec{u} 上的投影距离 s:

$$s = \|\vec{a}\| \cdot \cos \theta = \frac{\vec{a} \cdot \vec{u}}{\|\vec{u}\|} = \vec{a} \cdot \vec{u}$$

其中： θ 表示两个向量之间的夹角

$$\therefore a_u = \vec{u}^T \cdot \vec{a}, a_v = \vec{v}^T \cdot \vec{a}$$

\therefore 向量 \vec{a} 在新坐标系中的坐标可以表示为：

$$\vec{a}_{new} = [\vec{u} \quad \vec{v}]^T \cdot \vec{a} = \begin{bmatrix} \vec{u}^T \cdot \vec{a} \\ \vec{v}^T \cdot \vec{a} \end{bmatrix}$$

如果矩阵 A 的列向量分别表示原来坐标系中的点，那么在新坐标系中的坐标为：

$$A_{new} = [\vec{u} \quad \vec{v}]^T \cdot A$$

如果 \vec{a}_{center} 表示一系列数据点的中心，那么可以证明：

$$\vec{a}_{newcenter} = [\vec{u} \quad \vec{v}]^T \cdot \vec{a}_{center}$$

经过上面的变换之后，新坐标系相比原坐标系顺时针旋转了45度； \vec{a} 相对新坐标系位置和相对原坐标系位置发生了逆时针旋转45度。即：上述变换过程为向量的旋转过程，旋转的角度=坐标系旋转角度

如果 $\|\vec{u}\| \neq 1, \|\vec{v}\| \neq 1$ ，那么：


$$\begin{aligned} \vec{u}^T \cdot \vec{a} &= s \cdot \|\vec{u}\| \\ \vec{v}^T \cdot \vec{a} &= s \cdot \|\vec{v}\| \end{aligned}$$

即： \vec{a}_{new} 相比 \vec{a} ，2个坐标分别放大了 $\|\vec{u}\|$ 倍和 $\|\vec{v}\|$ 倍。即向量发生了伸缩。

2.2 拉格朗日乘法⁺

拉格朗日乘法主要提供了一种求解函数在约束条件下极值的方法。下面还是通过一个例子说明。

假设存在一个函数 $f(x, y)$ ，求该函数在 $g(x, y) = c$ 下的极值（可以是极大，也可以极小）



通过观察我们发现，在极值点的时候两个函数必然相切，即此时各自的导数成正比，从而：

$$\begin{aligned} \frac{\partial f}{\partial x} &= \lambda \frac{\partial g}{\partial x} \\ \frac{\partial f}{\partial y} &= \lambda \frac{\partial g}{\partial y} \\ g(x, y) &= c \end{aligned}$$

通过联立上述三个公式，既可以求出最终结果。拉格朗日算子的主要思路同上，不过他假设了一个新的函数：

$$F(x, y, \lambda) = f(x, y) + \lambda[c - g(x, y)]$$

然后分解求：

$$\begin{aligned}\frac{\partial F}{\partial x} &= 0 \\ \frac{\partial F}{\partial y} &= 0 \\ \frac{\partial F}{\partial \lambda} &= 0\end{aligned}$$

从而完成求解过程

2.3 协方差矩阵⁺

假设有一组数据：

样本编号	变量 x （如发传单数量）	变量 y （如购买数量）	变量 z （如购买总价）
1	1	2	3
2	35	25	55
...

协方差研究的目的是变量（特征）之间的关系，也就是上表中的发传单数量、购买数量、购买总额之间的相关情况

上表数据用矩阵表示为：

$$X = \begin{bmatrix} 1 & 35 & \dots \\ 2 & 25 & \dots \\ 3 & 55 & \dots \end{bmatrix}$$

那么两两变量之间的关系：

$$\begin{aligned}cov(x, y) &= E[(1 - E(x))(2 - E(y)) + (35 - E(x))(25 - E(y)) + \dots] \\ cov(x, z) &= E[(1 - E(x))(3 - E(z)) + (35 - E(x))(55 - E(z)) + \dots] \\ &\dots\end{aligned}$$

如果 $E(x)=E(y)=E(z)=0$ （可以通过数据初始化实现），那么上述的协方差关系可以用如下矩阵乘法表示：

$$cov(X) = \frac{1}{m} X X^T = \begin{bmatrix} cov(x, x) & cov(x, y) & cov(x, z) \\ cov(y, x) & cov(y, y) & cov(y, z) \\ cov(z, x) & cov(z, y) & cov(z, z) \end{bmatrix}$$

如果把对角线上的数据加起来会发现：

$$\begin{aligned}& cov(x, x) + cov(y, y) + cov(z, z) \\ &= E[[(1 - E(x))^2 + (2 - E(y))^2 + (3 - E(z))^2] + \dots] = \frac{1}{m} \sum_{i=1}^m \|X_i - X_{center}\|^2\end{aligned}$$

也就是说每个样本点到样本中心距离的平方和的平均 = 样本各个特征方差和（自身协方差） = $\sum diag(\frac{1}{m} X X^T)$ ，即样本的方差

2.4 特征向量和奇异值分解⁺

2.4.1 特征向量


参考：

特征值和特征向量

www.jianshu.com/p/f5e72e6ca289



假设：左侧矩形由 $\begin{bmatrix} \vec{i} & \vec{j} \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$ 定义，右侧矩形由 $\begin{bmatrix} \vec{i}' & \vec{j}' \end{bmatrix} = \begin{bmatrix} 2 & 0 \\ 0 & 0.5 \end{bmatrix}$ 定义。



Eigenvectors (red) do not change direction when a linear transformation (e.g. scaling) is applied to them. Other vectors (yellow) do.

根据 2.1 矩阵拉伸变换的结果，变换矩阵 $A = \begin{bmatrix} \vec{u}^T \\ \vec{v}^T \end{bmatrix} = \begin{bmatrix} 2 & 0 \\ 0 & 0.5 \end{bmatrix}$ ，即：

$$A \cdot \begin{bmatrix} \vec{i} & \vec{j} \end{bmatrix} = \begin{bmatrix} \vec{i}' & \vec{j}' \end{bmatrix}$$

在应用变换矩阵变换时，我们发现存在与上图中红色向量平行的向量 \vec{a} ，他们总满足：

$$A \cdot \vec{a} \parallel \vec{a}$$

即：

$$A \cdot \vec{a} = \lambda \cdot \vec{a}$$

所以：红色的特征向量不受变换矩阵的影响，仍保持原来的方向，我们称这类向量为变换矩阵A的特征向量，对应的 λ 为特征值。又因为特征向量有很多个，即：

$$A \cdot \vec{a}_i = \lambda_i \cdot \vec{a}_i$$

所以：

$$A \cdot \begin{bmatrix} \vec{a}_1 & \vec{a}_2 & \dots \end{bmatrix} = \begin{bmatrix} \vec{a}_1 & \vec{a}_2 & \dots \end{bmatrix} \cdot \begin{bmatrix} \lambda_1 & & \\ & \lambda_2 & \\ & & \ddots \end{bmatrix} \Rightarrow A = Q \cdot \Sigma \cdot Q^{-1}$$

其中：Q的列向量都是A变换矩阵的特征向量

另外，在做旋转变换时，要求变换前后的坐标维度不发生改变，即A须为方阵

综上：如果方阵A满足 $A = Q \cdot \Sigma \cdot Q^{-1}$ ，那么Q为特征向量， Σ 为对应的特征值

2.4.2 奇异值分解

奇异值分解 (svd: singular value decomposition) 定义：对于任意的矩阵A，存在：

$$A_{m \times n} = U_{m \times m} \cdot \Sigma_{m \times n} \cdot V_{n \times n}^T$$

其中：

$$\begin{aligned} U^T \cdot U &= I_m \\ V^T \cdot V &= I_n \end{aligned}$$

即：U的列向量两两正交且模为1，V列向量两两正交且模为1，即：

$$\begin{aligned} U^T &= U^{-1} \\ V^T &= V^{-1} \end{aligned}$$

2.4.3 特征向量和奇异值分解的关系

对于任意矩阵 A ，对A做svd有：

$$AA^T = U \Sigma V^T \cdot V \Sigma U^T = U \Sigma^2 U^{-1}$$

令 $\Sigma' = \Sigma^2$ ，则：

$$\begin{aligned} AA^T &= U \Sigma' U^{-1} \\ \text{满足 } A &= Q \Sigma Q^{-1} \text{ 特征向量定义} \end{aligned}$$

所以 AA^T 能实现特征分解，又因为：

$$AA^T = \underbrace{U'' \Sigma'' V''^T}_{svd}$$

所以：

$$\begin{aligned} U &= U'' \\ \Sigma' &= \Sigma'' \\ U^{-1} &= V''^T \Rightarrow U = V'' \end{aligned}$$

因此：对 AA^T 做SVD，那么得到的U''列向量为特征向量（对应A的U矩阵）， Σ'' 为特征值对角阵

同理：对 $A^T A$ 做SVD，那么得到的U''列向量为特征向量（对应A的V矩阵）， Σ'' 为特征值对角阵

3 PCA

3.1 PCA推导

PCA的目标是找到一组新的正交基 $\{u_1, u_2, \dots, u_k\}$ （从n维下降到k维），使得数据点在该正交基构成的平面上投影后，数据间的距离最大，即数据间的方差最大。如果数据在每个正交基上投影后的方差最大，那么同样满足在正交基所构成的平面上投影距离最大。

根据2.1，设正交基 u_j ，数据点 x_i 在该基底上的投影距离为 $x_i^T \cdot u_j$ ，所以所有数据在该基底上投影的方差 J_j 为：

$$J_j = \frac{1}{m} \sum_{i=1}^m (x_i^T u_j - x_{center}^T u_j)^2$$

其中：m为样本数量，在数据运算之前对数据 x 进行0均值初始化，即 $x_{center} = 0$ ，从而：

$$J_j = \frac{1}{m} \sum_{i=1}^m (x_i^T u_j)^2 = \frac{1}{m} \sum_{i=1}^m (u_j^T x_i \cdot x_i^T u_j) = u_j^T \cdot \frac{1}{m} \sum_{i=1}^m (x_i x_i^T) \cdot u_j$$

所以：

$$J_j = u_j^T \cdot \frac{1}{m} (x_1 x_1^T + x_2 x_2^T + \cdots + x_m x_m^T) \cdot u_j = u_j^T \cdot \frac{1}{m} ([x_1 \quad \cdots \quad x_m] \cdot \begin{bmatrix} x_1 \\ \vdots \\ x_m \end{bmatrix}) \cdot u_j = \frac{1}{m} u_j^T X X^T u_j$$

由于 $\frac{1}{m} X X^T$ 为常数，这里假设 $S = \frac{1}{m} X X^T$ ，则： $J_j = u_j^T \cdot S \cdot u_j$ ，根据PCA目标，我们需要求解 J_j 最大时对应的 u_j

根据 2.2 中的拉格朗日算子（求极值）求解：

$$\begin{aligned} J_j &= u_j^T S u_j \\ s.t. \quad u_j^T u_j &= 1 \end{aligned}$$

则构造函数：

$$F(u_j) = u_j^T S u_j + \lambda_j (1 - u_j^T u_j)$$

求解 $\frac{\partial F}{\partial u_j} = 0$ ，得：

$$2S \cdot u_j - 2\lambda_j \cdot u_j = 0 \Rightarrow S u_j = \lambda_j u_j$$

结合2.4.1则：当 u_j 、 λ_j 分别为S矩阵的特征向量、特征值时， J_j 有极值，把上述结果带回公式得：

$$J_{j\max} = u_j^T \lambda_j u_j = \lambda_j$$

所以对于任意满足条件的正交基，对应的数据在上面投影后的方差值为S矩阵的特征向量，从而：

$$J_{\max} = \sum_{j=1}^k \lambda_j, \lambda \text{ 从大到小排序}$$

所以投影正交基为S的特征向量中的前k个最大特征值对应的特征向量。

接下来对S进行特征分解，根据2.4.3特征向量和svd的关系结论，S的特征向量集合：

$$U = U \text{ of } svd(S) = U \text{ of } svd(\frac{1}{m} X X^T)$$

另外，由于 $S = \frac{1}{m} X X^T$ 由于X已0均值处理，根据2.3 协方差矩阵定义：S为数据集X的协方差矩阵。

综上，即可得到满足投影后数据距离最大的新的正交基 $\{u_1, u_2, \cdots, u_k\}$

因此：

$$X_{new_{k \times m}} = \begin{bmatrix} u_1^T \\ u_2^T \\ \vdots \\ u_k^T \end{bmatrix}_{k \times n} \cdot X_{n \times m}$$

3.2 PCA过程总结

PCA流程如下：

1. 初始化X，使得所有样本之间的特征值均值为0，同时应用feature scaling，缩放到-0.5~0.5；
2. 计算X的协方差矩阵S；
3. 对S进行SVD分解，U即我们要求的新坐标系集合， Σ 为特征值集合（计算时特征值都会大于0，且结果会从小到大排列）；
4. 按照特征值从大到小排序，要降低为k维，那么取前k个特征值对应的特征向量，就是新的k个坐标轴
5. 把X映射到新的坐标系中，完整降维操作；

根据之前的公式，做PCA投影后，投影数据的方差：

$$Var_{X_{project}} = \sum_{j=1}^k J_j = \sum_{j=1}^k \lambda_j$$

又因为：数据从n维投影新的n维的坐标系，方差不会发生改变（向量的模长度相等且为1，可以用2D坐标系投影到45-135度坐标系验证），即：

$$Var_X = Var_{X_{project}} = \sum_{j=1}^n J_j = \sum_{j=1}^n \lambda_j$$

即：X的协方差矩阵的特征值和对应X的方差

3.3 主成份数量的选择

PCA使得数据从n维降低为k维度，接下来介绍如何选择合适的k。一般选择标准为：投影前后方差比例值，作为k值的选择标准。距离来说，我们期望：

$$\frac{Var_{X_{project}}}{Var_X} \geq q$$

其中q一般选择0.99。根据PCA总结中特征协方差矩阵和X方差的关系得：

$$\frac{Var_{X_{project}}}{Var_X} = \frac{\sum_{j=1}^k \lambda_j}{\sum_{j=1}^n \lambda_j} \geq 0.99$$

因此主成份数量k根据上述公式求得满足条件的最小k

本文同时发布于CSDN博客：

详细推导PCA算法（包括算法推导必备的知识） - 怪兽 - CSDN博客

[blog.csdn.net/QQ2627866800/article/deta...](https://blog.csdn.net/QQ2627866800/article/details/121111111)



所属专栏 · 2025-04-10 23:35 更新



AI怪兽专栏

怪兽

29 篇内容 · 619 赞同

订阅

最热内容 · KV Cache 技术分析

编辑于 2021-12-01 17:37

机器学习 矩阵论 线性代数

10 条评论

默认 最新



脑子空空无所谓

PCA流程里面第三步，难道不是 对X进行SVD分解，对S求特征值特征向量

2019-03-17

回复 2



随遇则安

既然说S是常数，那怎么最后又写的是S矩阵，然后根据是矩阵又得出推导的那些量是特征向量和特征值呢？

2023-10-22

回复 1



悄然改变

这推导过程有问题

2024-06-03

回复 喜欢



clay

3.1最开始这里，“如果数据在每个正交基上投影后的方差最大，那么同样满足在正交基所构成的平面上投影距离最大”，应该是投影距离最小吧

2019-11-02

回复 3



许光达

推导的比较清晰

2023-04-01

回复 喜欢



cyh

写得很详细，但是我想问一下，在3.1的推导中，由于u是正交基，求极值的约束条件不应该只有 u_j 乘以 u_j 的转置为1，还应该满足不同的u之间的内积为0。这边是如何满足这个约束条件的呢

2022-08-10

回复 喜欢



小甜同学

想问下，为什么 $E(X)=0, E(Y)=0, E(Z)=0$ 之后，就可以用下面的式子表示了，

2021-09-09

回复 喜欢



Prac

很详细，但是2.3协方差矩阵中的X的内容是不是写成了转置呢？是不是应该是 $[[1,2,3], [35,25,55], \dots]$ 呢？

2019-04-24

回复 喜欢



怪兽 作者

一般我们处理数据时，一条数据作为一个向量，而向量我们默认是列向量

2019-04-26

回复 1



Nathan Wan


相当不错，深入浅出

2019-02-07

回复 喜欢


推荐阅读

CA...



你真的懂PCA了？

一文



PCA算法总结


yhang...

发表于路曼曼其修...

PCA算法

原文来自 主成分分析（PCA）原理总结 - 刘建平Pinard - 博客园，文章对PCA算法做了详细介绍，总结如下。主成分分析（Principal components analysis，以下简称PCA）是最重要的降维方法之一...

漫漫成长



【机器学习基础】感知机
Softmax loss函数梯度求导...

衍衍子

发表于EECS体...